

Komentarji na osnutek magistrske naloge

12. 5. 2026

Komentarje sem razdelil na dva dela:

- **Zelena polja (OK)** = tvoja osrednja raziskava in vse, kar lahko gre v naloge v celoti, brez kakršne koli spremembe.
- **Oranžna polja (POMEMBNO)** = dva odseka, ki potrebujeta prilagoditev. Za oba sem ti pripravil predlog, kako lahko stvar formuliraš drugače, da boš imel čim manj dela.

Naloga ostane vsebinsko močna tudi po teh prilagoditvah — ker je tvoja glavna tema (primerjava pose estimation modelov in učenje YOLO-ja na lastni množici) povsem nedotaknjena.

Kar lahko ostane v celoti

To je tvoja osrednja raziskava in tvoj znanstveni prispevek. Tukaj nimaš za kaj skrbeti — objavi v polnem obsegu, brez sprememb.

OK Poglavlje 1 – Uvod (opis problema, cilji)

Vse ostane. Splošen opis problemskega področja, brez konkretnih implementacijskih razkritij.

OK Poglavlje 2 – Pregled in opis modelov (MediaPipe, YOLO, PoseNet, MoveNet, BlazePose)

Celo poglavje ostane, vključno z vsemi opisi posameznih modelov, številkami sklepnih točk, konfiguracijami in opisom WebAssembly/WebGL/WebGPU zaledij. To so vse javno dokumentirani modeli in javne tehnologije — tu nič ni poslovne skrivnosti. Tvoja tema, tvoj pregled, gradiš na javnih virih.

OK Poglavlje 3 – Primerjava in uspešnost modelov (MPJPE, PCK, FPS, sklepi)

Celo poglavje ostane, vključno z metodologijo MPJPE in PCK, primerjavo FPS, analizo napak po sklepnih točkah in sklepno evalvacijo (str. 26–27), kjer ugotoviš, da je MediaPipe PoseLandmarker najboljša izbira med primerjanimi modeli. To je tvoja akademska ugotovitev na podlagi tvoje primerjave in glavni znanstveni prispevek tvoje naloge. Glede MediaPipe lahko napišeš, kar koli želiš — tudi končno priporočilo. Tu nimam zadržkov.

OK Poglavlje 5 – Učenje modela YOLO11n-pose

Celotno poglavje učenja modela ostane: izbira YOLO11n-pose 256x256, hiperparametri (200 epoh, ločljivost 256), data.yaml konfiguracija, grafi izgube in metrik, doseženi rezultati po učenju (MPJPE 0.016 vs. 0.036 izhodiščna). To je tvoja izvedba in tvoj merljiv rezultat. Drugi glavni prispevek naloge in seveda gre v celoti notri.

OK Viri in literatura

Vsi viri so javni in ustrezno citirani. Ostane brez sprememb.

Skupaj je to približno tri četrtine naloge, ki ostane povsem nedotaknjena. Zdaj pa k dvema odsekoma, kjer je potrebna prilagoditev.

Kar potrebuje prilagoditev

POMEMBNO **Poglavje 4 – Lastna učna množica (str. 28–32)**

Težava tu je, da naloga eksplicitno omenja zajem podatkov iz produkcijske aplikacije in 134 unikatnih uporabnikov. Dvojno občutljivo — razkriva, da Fitcode produkcijska aplikacija obstaja in da se uporablja za zajem podatkov, in odpira GDPR vprašanje (soglasja uporabnikov verjetno niso bila pripravljena za objavo v javni magistrski). Predlagam, da poglavje 4 reformuliraš v generično obliko.

Predlog nadomestnega besedila:

Za potrebe učenja in evalvacije izbranega modela je bila pripravljena lastna učna množica slik vadbe, zbrana v okviru raziskovalnega projekta. Udeleženci so podali soglasje za uporabo gradiva v raziskovalne namene.

Označevanje sklepnih točk v učni množici je bilo opravljeno s pomočjo visokozmogljivega modela RTMO-X, ki je deloval v vlogi "učitelja" in generiral referenčne napovedi. Tak pristop omogoča označevanje velikega števila slik brez ročnega označevanja vsake sklepne točke.

Pred označevanjem je bil opravljen postopek čiščenja, pri katerem so bile izločene slike, ki niso bile primerne za učenje (več oseb v kadru, delna vidnost osebe, popačenja, nenaravne poze).

Učna množica je bila razdeljena v razmerju 80/10/10 na učni, validacijski in testni del. Pri analizi učne množice je bila ocenjena zastopanost posameznih vaj (Slika 10). Identitete vseh udeležencev so anonimizirane in se ne razkrivajo.

Glede slik v poglavju 4:

- **Slika 10** (histogram vaj) — ostane.
- **Slika 11** (histogram uporabnikov) — odstrani. Informacija o 134 uporabnikih je poslovno občutljiva.
- **Slike 12–17** (primeri slik iz učne množice, na katerih si ti) — lahko ostanejo, ker si na njih ti sam. Če bi bil na katerikoli sliki še kdo drug, to odstrani.

POMEMBNO **Poglavje 6 – Spremljanje in analiza vadbe (str. 39–57)**

To je glavni izziv. Trenutno poglavje 6 vsebuje praktično celotno arhitekturo in algoritme Fitcode produkta — imena stanj state machine, algoritem detekcije ponovitev, izračun izometrične faze, strukturo predpisov za vaje, algoritem kalibracije piksel-meter, algoritem višine skoka in klasifikacijsko logiko Velocity-Based Training. To je v bistvu naš core IP, opisan na način, da bi konkurent lahko relativno hitro klonira sistem. Predlagam, da celotno poglavje 6 (trenutnih približno 18 strani) nadomestiš s krajšim, na visoki ravni napisanim poglavjem (2–3 strani).

Predlog nadomestnega besedila:

6. Integracija v sistem za spremljanje vadbe

Optimalno izbran in dodatno naučen model za zaznavo drže je bil integriran v sistem za realno-časovno spremljanje in analizo vadbe. Ta razdelek na visokem nivoju opisuje arhitekturni pristop in znanstvene koncepte, na katerih sistem temelji. Konkretno implementacijske podrobnosti (arhitektura končnega avtomata, algoritmi detekcije ponovitev, klasifikacijski algoritmi, pragovi in poslovna pravila) so del lastne implementacije naročnika in v tem magistrskem delu niso podrobno razkrite.

6.1. Vodenje uporabnika skozi vadbo. Sistem uporablja vzorec končnega avtomata (state machine) za vodenje uporabnika skozi tri glavne faze: pripravljalno (preverjanje vidnosti uporabnika v kadru in stabilnosti drže), izvedbeno (zajemanje in analiza ponovitev) in zaključno (shranjevanje rezultatov). Vsako stanje preverja specifične pogoje pred prehodom v naslednje, kar zagotavlja, da analiza ponovitev poteka šele, ko so vhodni podatki dovolj stabilni in zanesljivi.

6.2. Zajemanje ponovitev in biomehanske faze. Za vsako ponovitev sistem določi trajanje treh biomehanskih faz: koncentrične (krčenje glavne mišice ob premagovanju upora), ekscentrične (raztezanje mišice ob kontroliranem zaviranju) in izometrične (kratek statični del med fazama). Definicije faz so povzete iz uveljavljene biomehanske literature. Sistem zajame časovne, prostorske in hitrostne metrike, ki služijo nadaljnji analizi.

6.3. Povratne informacije in zaznavanje tehničnih napak. Sistem uporabniku med vadbo prikazuje različne grafične povratne informacije (časovni grafi, grafi prepotovane distance, grafi hitrosti). Zaznava tudi tehnične napake na ravni posamezne ponovitve. Detekcija temelji na geometrijskih odnosih med zaznanimi sklepnimi točkami: kotih med izbranimi sklepi, relativnih razdaljah med regijami in časovni stabilnosti odstopanj.

6.4. Kalibracija in metrične enote. Za pretvorbo med pikselskimi koordinatami in realnimi enotami sistem zahteva vnos uporabnikove telesne višine, ki služi kot referenca. Postopek kalibracije omogoča izračun razdalj med sklepnimi točkami v metrih, kar je potrebno za merjenje distance in hitrosti gibanja v realnih enotah. Sistem podpira tudi merjenje višine skoka v metričnih enotah.

6.5. Analiza na podlagi hitrosti. Sistem implementira metode za analizo vadbe na podlagi hitrosti koncentrične faze posameznih ponovitev (Velocity-Based Training, splošno priznan koncept v športni znanosti). Izmerjeni podatki omogočajo primerjave znotraj serije, med serijami in dolgoročne trende skozi več treningov. Konkretni klasifikacijski algoritmi in pragovi so del lastne implementacije naročnika.

Glede slik v poglavju 6: vse slike 23–53 (stanja state machine, prehodi, ponovitve, povratne informacije, kalibracija, merjenje skoka) je smiselno odstraniti. So zaslonski posnetki aplikacije in razkrivajo UI ter imena stanj.